

Contrastive Counterfactual Learning for Causality-aware Interpretable Recommender Systems(CIKM '23)

Zhou et al., 2023

Jiun Jeong

March 11, 2025

Introduction

Proposition method

Experiments

Introduction

- 추천 시스템은 일반적으로 특정 아이템이 유저에게 노출(Exposure)되고, 유저가 이를 평가(Rating)한 피드백 데이터를 기반으로 학습
- 이러한 시스템은 유저에게 노출되지 않은 아이템에 대한 의견을 파악할 수 없어 데이터가 불완전함
- 불완전 데이터에 의한 왜곡된 노출 매커니즘은 일부 아이템 위주로 노출되게 되는 현상이 발생하는데, 이를 **노출 편향(Exposure bias)**라고 함

노출 편향(Exposure bias)의 원인: 관측 데이터의 불완전성

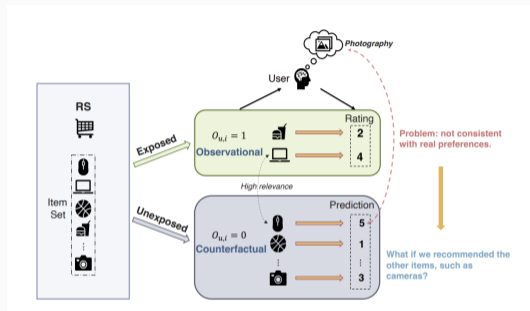


Figure 1: 관측 데이터의 불완전성에 의해 선호가 왜곡됨

- 유저가 카메라를 좋아하지만 컴퓨터와 마우스만 노출되어, 시스템이 사용자가 카메라를 좋아할 가능성을 전혀 학습하지 못함

- 아이템 노출 메커니즘이 문화적 차이, 지역적 제한 등 숨겨진 요인의 영향을 받음.

ex) 특정 지역에서만 제공되는 상품이 해당 지역 사용자에게만 노출됨

- 논문에서는 유저에게 아이템이 랜덤하게 노출되는 상황을 만들어, 고유한 선호를 찾고자 함
 - 데이터 생성 과정에 대한 인과그래프(Structural Causal Models, SCMs) 정의
 - SCM을 활용해 데이터의 변수 간 관계를 명시적으로 모델링함으로써, 혼란 변수가 사용자 선호도와 노출 매커니즘 사이에 미치는 영향을 차단
 - 각 아이템이 동일한 확률로 노출되는 가상의 실험적 시나리오를 구현
 - Contrastive Self-Supervised Learning (SSL)의 활용
 - SSL 프레임워크를 사용해 유저-아이템 임베딩 표현을 학습하고, 노출 편향을 완화
 - Contrastive Counterfactual Learning(CCL)
 - 랜덤한 반사실적 샘플을 활용해, 노출되지 않은 아이템에서도 유저의 선호도를 잘 반영하도록 모델 학습
- 이러한 방식을 통해 노출 매커니즘이 편향되는 것을 막아 다양한 아이템이 노출되도록 유도

Proposition method

제안된 방안 1: 인과 그래프 정의




Figure 2: 인과 그래프를 활용하여 추천 시스템의 데이터 생성 과정에서 발생하는 confounder(혼란 변수)가 유저와 아이템 간 상호작용(노출 메커니즘)에 미치는 영향을 분석

- $\{Z \rightarrow Y\}$: 혼란 변수는 선호도에 직접적인 영향을 미칠 수 있음. 예를 들어, 문화적 차이로 특정 지역의 사람들은 특정 장르의 영화를 선호할 수 있음
- $\{Z \rightarrow I\}$: 혼란 변수에 의해 일부 아이템만 관측됨. 이는 유저와 아이템 간의 거짓된 상관관계를 만들 수 있음

- 일반적인 학습 방법으로는 상호작용 하지 않은 아이템은 단순히 선호할 가능성이 낮다고 추론하기 때문에, **SSL(Contrastive Self-Supervised Learning)**을 활용하여 표현(representation) 학습을 개선

$$\mathcal{L}_{\text{con}} \triangleq \frac{1}{|\mathcal{D}|} \sum_{\substack{(u,i) \in \mathcal{D}, \\ i^+ \sim p_{\text{pos}}, \\ i^- \sim p_{\text{data}}}} -\log \frac{\exp(\phi_{\theta}(u, i^+))}{\exp(\phi_{\theta}(u, i^+)) + \sum_{i^-} \exp(\phi_{\theta}(u, i^-))} \quad (1)$$

- 유저와 상호작용한 아이템을 Positive sample로 취급하는 기존의 방법은 노출 편향에 의해 유저의 진정한 선호를 반영하지 못함
→ 이에 대해 논문에서는 새로운 Positive sampling 기법을 활용한 데이터 증강(Augmentation)을 통해 다양한 아이템이 노출되도록 유도

- Contrastive Counterfactual Learning

$$\tilde{h}_{2k-1} = g_u(x_u) \oplus g_i(x_i) \quad (2)$$

$$\tilde{h}_{2k} = g_u(t(x_u)) \oplus g_i(t(x_i)) \quad (3)$$

$$l_{\text{ccl}}(\tilde{h}_{2k-1}, \tilde{h}_{2k}) = -\log \frac{\exp(\text{sim}(\tilde{h}_{2k-1}, \tilde{h}_{2k})/\tau)}{\sum_{m=1}^{2N} \mathbf{1}_{[m \neq 2k-1]} \exp(\text{sim}(\tilde{h}_{2k-1}, \tilde{h}_m)/\tau)} \quad (4)$$

$$\mathcal{L}_{\text{ccl}} = \frac{1}{2N} \sum_{k=1}^N \left[l_{\text{ccl}}(\tilde{h}_{2k-1}, \tilde{h}_{2k}) + l_{\text{ccl}}(\tilde{h}_{2k}, \tilde{h}_{2k-1}) \right] \quad (5)$$

여기서 $g_u(x_u), g_i(x_i)$ 는 특정 유저 u 와 아이템 i 의 representation, \oplus 는 concat함수를 의미

- Anchor의 표현인 (2)와 샘플링된 $t(x_u), t(x_i)$ 의 표현인 (3)이 가까워지도록 학습

- 논문은 세가지의 positive sampling 방법을 제안하여 다양한 아이템이 노출되도록 유도
 - Propensity score-based sampling: Naive Bayes 추정기 또는 로지스틱 회귀 모형으로 추정한 propensity score를 기반한 샘플링 방법으로, 기준인 Anchor와 propensity score가 가장 많이 차이나는 아이템을 샘플로 사용
 - Item popularity-based sampling: 아이템 인기를 사용하여 Anchor와 인기도 차이가 가장 큰 아이템을 샘플로 사용
 - Random counterfactual sampling: 유저 u 와 상호작용이 없는 아이템(Counterfactual)을 랜덤하게 뽑아 샘플로 사용

- 아래의 수식을 통해 training과정에서 학습함

$$\mathcal{L} = \mathcal{L}_{\text{rec}} + \lambda \mathcal{L}_{\text{ccl}} \quad (6)$$

$$\mathcal{L}_{\text{rec}} = \sum_{k=1}^N -\hat{y}_{u,i} \cdot \log(f(\tilde{h}_{2k-1})) - (1 - \hat{y}_{u,i}) \cdot \log(1 - f(\tilde{h}_{2k-1})) \quad (7)$$

$$\mathcal{L}_{\text{ccl}} = \frac{1}{2N} \sum_{k=1}^N \left[l_{\text{ccl}}(\tilde{h}_{2k-1}, \tilde{h}_{2k}) + l_{\text{ccl}}(\tilde{h}_{2k}, \tilde{h}_{2k-1}) \right] \quad (8)$$

- 여기서 $f(\cdot)$ 는 Neural network layers을 나타냄

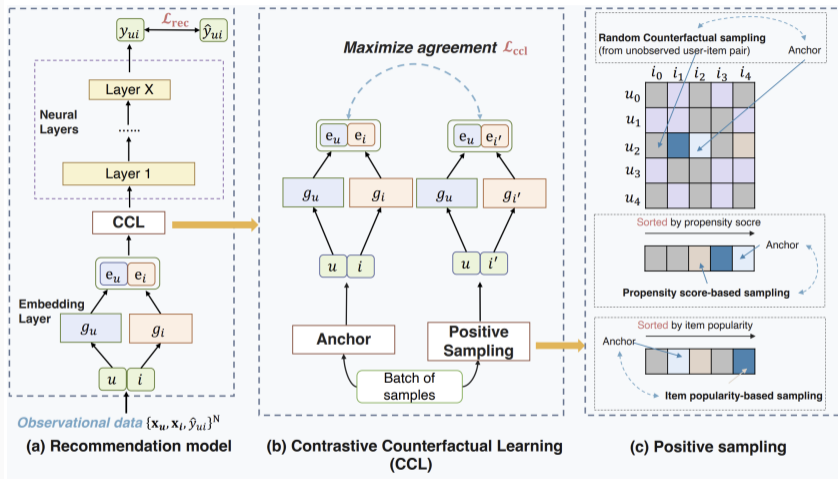


Figure 3: 논문에서 제안한 프레임워크

Experiments

- 실험을 위한 데이터는 Coat와 Yahoo! R3를 사용
 - Coat데이터: 쇼핑 웹사이트의 Coat 데이터로 290명의 유저와 300개의 아이템으로 구성됨. training 과정에서는 각 유저가 24개의 아이템에 대해 평점을 남기고, test 과정에서는 무작위로 표시된 16개의 아이템에 대한 평점을 남김
 - Yahoo! R3 데이터: 유저와 노래 평점 데이터로 train데이터는 15,400명의 유저가 남긴 30만건의 평점 데이터, test데이터는 5,400명의 유저가 무작위로 선택된 10곡에 대한 평점 데이터로 구성
- 두 데이터 모두 test데이터에서 무작위 노출을 기반으로 한 편향되지 않은 데이터로 구성 되어있어, 노출 편향이 제거된 상황을 가정함

Dataset	Methods	NDCG@5 \uparrow	NDCG@10 \uparrow	Recall@1 \uparrow	Recall@5 \uparrow	MRR \uparrow	Gini \downarrow	Global Utility \uparrow
Coat	MF	0.618878	0.685805	0.143029	0.470560	0.724109	0.328557	<u>0.519310</u>
	+IPS	0.546103	0.642255	0.137241	0.445300	0.695958	0.370406	0.465517
	+SNIPS	0.619469	0.693272	0.130670	0.472532	0.702422	0.335425	0.509655
	+DR	0.610190	0.683095	0.142121	0.458575	0.723581	0.335808	0.506207
	+CVIB	0.635618	0.706618	0.154944	0.485840	<u>0.753408</u>	0.333855	0.515172
	NCF	0.613597	0.686848	0.155841	0.478001	0.727774	0.356257	0.502483
	+IPS	0.615375	0.692377	0.149823	0.469947	0.726316	0.347815	0.506897
	+SNIPS	0.619516	0.697859	0.156743	0.464328	0.739233	0.343668	0.509655
	+DR	<u>0.636087</u>	<u>0.708855</u>	0.152474	0.469774	0.726123	0.331799	0.519310
	+CVIB	<u>0.627515</u>	0.702538	0.155350	<u>0.488107</u>	0.742603	0.341349	0.5155862
	LightGCN	0.598313	0.671740	0.133139	0.454676	0.698339	0.358796	0.502759
	CCL w/ps	0.631428	0.705370	0.158229	0.478170	0.748094	<u>0.325380</u>	0.513103
	CCL w/pop	0.614438	0.690041	0.136208	0.461086	0.735151	0.330061	0.513103
	CCL w/cf	0.646099	0.715099	<u>0.156814</u>	0.490682	0.755027	0.312651	0.524828

Figure 4: Coat 데이터 실험 결과

Dataset	Methods	NDCG@5 \uparrow	NDCG@10 \uparrow	Recall@1 \uparrow	Recall@5 \uparrow	MRR \uparrow	Gini \downarrow	Global Utility \uparrow
Yahoo! R3	MF	0.634687	0.762871	0.381295	0.667766	0.436356	0.582162	0.252037
	+IPS	0.646120	0.765412	0.373860	0.700561	0.430910	0.557144	0.259889
	+SNIPS	0.638394	0.763969	0.381063	0.683709	0.432395	0.565564	0.251926
	+DR	0.656221	0.772937	0.385328	0.704601	0.444278	0.557553	0.263815
	+CVIB	<u>0.696131</u>	<u>0.799171</u>	<u>0.412612</u>	<u>0.738778</u>	<u>0.483970</u>	<u>0.541144</u>	0.278963
	NCF	0.654634	0.774168	0.383378	0.700092	0.443718	0.562444	0.260481
	+IPS	0.660373	0.775258	0.381428	0.710659	0.436361	0.548205	0.263970
	+SNIPS	0.652109	0.768611	0.390112	0.724687	0.452089	0.549243	0.261852
	+DR	0.647838	0.768016	0.387093	0.718626	0.452037	0.559978	0.259259
	+CVIB	0.667489	0.780986	0.394774	0.716073	0.456541	0.547794	0.2655923
	LightGCN	0.589551	0.730583	0.343585	0.645705	0.376967	0.582675	0.235222
	CCL w/ps	0.685223	0.792537	0.405060	0.730238	0.475835	0.544201	0.273185
	CCL w/pop	0.685183	0.792550	0.405038	0.730168	0.475966	0.544143	0.273111
	CCL w/cf	0.696671	0.799688	0.413482	0.739955	0.487297	0.537753	<u>0.277519</u>

Figure 5: Yahoo! R3 데이터 실험 결과

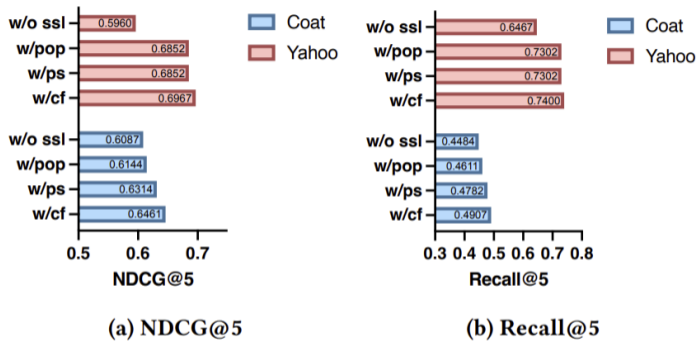


Figure 6: Sampling 방법에 따른 성능 변화

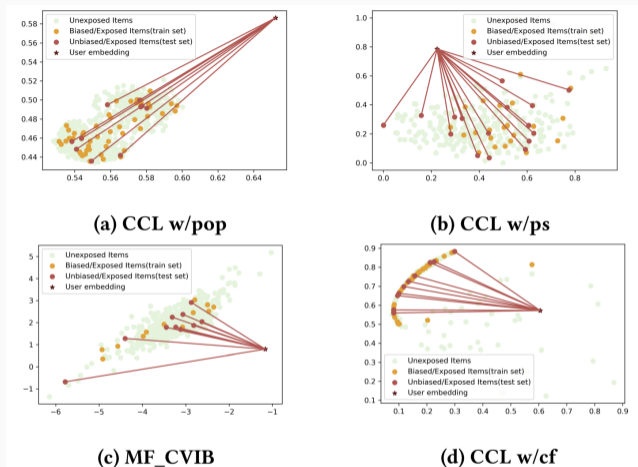


Figure 7: 사용자와 아이템 분포의 t-sne 그림. (d)그림에서 대부분의 아이템들이 유저에 대해 균등하게 분포되어 있음, 하지만 여전히 흩어져있는 아이템들은 모든 아이템을 완전히 샘플링하지 못한 결과

References



Zhou, G., Huang, C., Chen, X., Xu, X., Wang, C., Zhu, L., & Yao, L. (2023). **Contrastive counterfactual learning for causality-aware interpretable recommender systems.** *Proceedings of the 32nd ACM International Conference on Information and Knowledge Management*, 3564–3573. <https://doi.org/10.1145/3583780.3614823>